

LAPORAN TEKNIS DATA SCIENCE

Tim CC26-PSU125
Tema Sustainable Living & Responsible Consumption
Nama Proyek SayurKita

1. Problem Discovery

1.1 Krisis Food Waste di Indonesia

Indonesia termasuk salah satu negara dengan tingkat pemborosan makanan tertinggi di dunia. Berdasarkan data Bappenas (2021) dan laporan GRASP 2030 (2025), Indonesia membuang sekitar 48 juta ton makanan setiap tahunnya dengan kerugian ekonomi yang diperkirakan mencapai Rp 213 hingga Rp 551 triliun per tahun. Pemborosan makanan juga menyumbang sekitar 7,29% dari total emisi gas rumah kaca Indonesia.

Fakta yang perlu mendapat perhatian lebih adalah bahwa sekitar 80% dari pemborosan tersebut berasal dari tingkat rumah tangga, bukan dari industri pengolahan makanan atau restoran besar. Ini berarti intervensi yang paling langsung menyentuh akar masalah harus dilakukan di tingkat dapur rumah tangga sehari-hari.

1.2 Pernyataan Masalah

Berdasarkan kajian awal, terdapat tiga penyebab utama pemborosan makanan di tingkat rumah tangga Indonesia:

- Tidak adanya sistem pelacakan inventori bahan makanan yang proaktif. Pengguna umumnya tidak mengetahui bahan mana yang mendekati batas kedaluwarsa.
- Tidak tersedianya rekomendasi resep yang sesuai dengan sisa bahan yang masih ada di kulkas.
- Tidak ada mekanisme redistribusi makanan surplus yang mudah diakses dan berbasis komunitas lokal.

Solusi yang ada saat ini, seperti Surplus Indonesia atau Too Good To Go, bersifat reaktif dan menargetkan bisnis formal. Tidak ada yang secara khusus menyasar kebiasaan di tingkat rumah tangga.

1.3 Tujuan Analisis Data

Proyek SayurKita menggunakan pendekatan berbasis data untuk membangun tiga kapabilitas inti yang mendukung fitur MVP:

- 1. Sistem rekomendasi resep berbasis content-based filtering (TF-IDF) yang mencocokkan bahan sisa pengguna dengan resep masakan Nusantara yang tersedia. Kapabilitas ini mendukung fitur LihatKulkas.
- 2. Pelacakan umur simpan bahan makanan secara otomatis untuk memicu notifikasi expiry H-3 kepada pengguna. Kapabilitas ini memerlukan Ingredients Master dengan data shelf-life yang lengkap.
- 3. Kalkulasi dampak emisi karbon (CO2e) dari setiap aksi penyelamatan makanan, dengan konversi ke satuan yang lebih mudah dipahami pengguna. Kapabilitas ini mendukung fitur Jejak Hijau.

Untuk memenuhi ketiga tujuan tersebut, tim Data Scientist menghasilkan empat file output utama: `clean_recipes_5000_with_score.csv`, `ingredients_master_final.json` dan `nutrition_cleaned.csv`, serta `carbon_factors_indonesia.json`.

2. Data Wrangling

2.1 Data Gathering

Empat sumber data digunakan dalam proyek ini. Pemilihan masing-masing sumber didasarkan pada kebutuhan spesifik fitur SayurKita.

Dataset		Sumber	Format	Fungsi dalam SayurKita
Indonesian Recipes	Food	Kaggle	CSV	Basis TF-IDF recommendation engine untuk fitur LihatKulkas
Indonesian Nutrition	Food	Kaggle	CSV	Data kandungan gizi bahan untuk Nutrition Rescue Card
The Big Climate Database	Climate	CONCITO - thebigclimatedatabase.com (CC-BY 4.0)	JSON	Faktor emisi CO2e per bahan makanan
Ingredients Master		Dibuat mandiri oleh tim Data Scientist	CSV + JSON	Data umur simpan bahan, autocomplete, dan expiry tracking

Catatan: Ingredients Master adalah satu-satunya dataset yang tidak tersedia secara publik. Data umur simpan bahan dapur Indonesia belum pernah dikompilasi secara terstruktur sebelumnya, sehingga tim DS mengisinya secara manual mengacu pada TKPI Kemenkes dan referensi StillTasty.com

Catatan sumber karbon: The Big Climate Database (CONCITO, 2024) menggunakan metodologi Life Cycle Assessment (LCA) yang mencakup seluruh rantai pasokan mulai dari pertanian, perubahan penggunaan lahan tidak langsung (ILUC), pengolahan, kemasan, hingga distribusi ritel. Dataset ini dilisensikan CC-BY 4.0 dan memuat 536 faktor emisi untuk berbagai komoditas pangan.

2.2 Data Assessing

Sebelum proses pembersihan, setiap dataset diinspeksi untuk mengidentifikasi isu kualitas data.

A. Dataset Resep (raw: 14.945 baris, 5 kolom utama)

1. Terdapat duplikat judul resep yang perlu dihapus agar tidak menimbulkan bias representasi pada TF-IDF.
2. Sejumlah baris memiliki nilai kosong pada kolom Ingredients dan Steps yang merupakan kolom inti.
3. Distribusi kolom Loves sangat miring ke kanan: nilai minimum 6, median 12, rata-rata 22, dan maksimum 939. Tanpa normalisasi, resep dengan engagement tinggi akan mendominasi proses seleksi secara tidak proporsional.
4. Rentang Total Ingredients: 3 hingga 25 bahan. Rentang Total Steps: 2 hingga 23 langkah.

B. Dataset Nutrisi (raw: 1.346 baris, 7 kolom)

1. Kolom yang tersedia pada dataset raw: id, calories, proteins, fat, carbohydrate, name, image.
2. Tidak ditemukan missing values pada seluruh kolom.
3. Nilai kalori berkisar dari 0 hingga 940 kkal/100g. Nilai 0 merepresentasikan bahan non-kalori seperti air dan agar-agar, bukan data error.
4. Kolom id dan image tidak dibutuhkan untuk analisis dan dihapus saat proses cleaning.
5. Terdapat 102 baris yang dihapus saat cleaning karena duplikat nama setelah normalisasi, menghasilkan 1.244 baris bersih.

C. Ingredients Master (1.560 entri, 11 kolom)

1. Kolom umur_kulkas, umur_suhu_ruang, dan umur_freezer terisi 100% tanpa missing values.
2. Kolom karbon_co2e memiliki 650 nilai NULL (41,7%) terutama pada kategori bumbu dan rempah.
3. Kolom kalori_per_100g bernilai 0 untuk 1.112 entri (71,3%), artinya data gizi yang bermakna hanya tersedia untuk 448 bahan (28,7% dari total). Ini merupakan keterbatasan coverage yang perlu dicatat.

2.3 Data Cleaning

Proses pembersihan dirancang agar menghasilkan dataset yang representatif per kategori dan siap digunakan oleh TF-IDF engine.

A. Cleaning Dataset Resep – Dari 14.945 menjadi 5.000 resep

1. Hapus duplikat berdasarkan judul resep untuk menghindari bias representasi.
2. Hapus baris dengan nilai kosong pada kolom Ingredients atau Steps karena data tanpa komponen inti tidak dapat digunakan.

3. Normalisasi teks: lowercase dan strip karakter non-alfanumerik. Langkah ini kritis karena TF-IDF bersifat case-sensitive. Tanpa normalisasi, token 'wortel' dan 'Wortel' dianggap berbeda.
4. Filter kualitas minimum: Total Ingredients antara 3 dan 25 bahan, Total Steps minimal 2 langkah.
5. Seleksi top-625 per kategori untuk menghasilkan distribusi yang seimbang antar delapan kategori.

Hasil akhir: 5.000 resep bersih dengan distribusi tepat 625 resep per 8 kategori. Quality Score berkisar antara 0,08 hingga 0,80 dengan rata-rata 0,30 dan median 0,29.

B. Cleaning Dataset Nutrisi - 1.346 menjadi 1.244 baris

1. Normalisasi kolom name menjadi nama_bersih: lowercase dan strip whitespace.
2. Hapus kolom id dan image yang tidak dibutuhkan untuk analisis.
3. Rename kolom: calories menjadi kalori_per_100g, proteins menjadi protein_g, fat menjadi lemak_g, carbohydrate menjadi karbo_g.
4. Hapus 102 baris duplikat nama setelah normalisasi, menghasilkan 1.244 baris unik.
5. Left join ke Ingredients Master menggunakan nama_id dan nama_bersih sebagai key. Semua 1.560 bahan di master dipertahankan. Bahan tanpa padanan di dataset nutrisi menghasilkan nilai 0 pada kolom gizi.

C. Ingredients Master

Setelah merge dengan data nutrisi, ditambahkan kolom turunan risiko_suhu_ruang berdasarkan nilai umur_suhu_ruang dengan tiga kelas: Tinggi untuk bahan dengan umur simpan 3 hari atau kurang, Sedang untuk 4 sampai 7 hari, dan Rendah untuk lebih dari 7 hari. Kolom ini digunakan untuk menentukan urutan prioritas notifikasi di sistem.

3. Business Questions

Seluruh analisis eksplorasi diorganisasi di sekitar tujuh pertanyaan bisnis yang secara langsung menjawab kebutuhan fitur SayurKita MVP.

3.1 Pertanyaan dari Dataset Resep

No	Pertanyaan	Relevansi untuk SayurKita
PB-1	Kategori masakan apa yang paling banyak resepnya, dan apakah distribusinya seimbang?	Menentukan apakah strategi seleksi 625 resep per kategori menghasilkan dataset yang representatif untuk TF-IDF.
PB-2	Berapa rata-rata jumlah bahan per resep, dan apakah resep dengan bahan lebih sedikit lebih populer?	Mengevaluasi apakah TF-IDF dapat menghasilkan rekomendasi dari input minimal 2 sampai 3 bahan sisa.

PB-3	Bahan makanan apa yang paling sering muncul di seluruh resep Indonesia pada dataset raw?	Menentukan urutan prioritas autocomplete dan bahan yang perlu dipastikan akurat di Ingredients Master.
PB-4	Apakah resep dengan langkah lebih banyak (lebih kompleks) pada dataset raw mendapat engagement (loves) lebih tinggi?	Mengevaluasi apakah bobot skor_langkah dalam formula Quality Score dapat dijustifikasi secara data.

3.2 Pertanyaan dari Dataset Karbon

No	Pertanyaan	Relevansi untuk SayurKita
PB-5	Kategori makanan mana yang paling besar emisi CO ₂ -nya jika terbuang, dan seberapa besar perbedaannya?	Menentukan kategori mana yang harus mendapat prioritas notifikasi expiry tertinggi berdasarkan dampak lingkungan
PB-6	Jika rata-rata rumah tangga membuang 1 kg makanan per hari, berapa total CO ₂ yang bisa dicegah SayurKita dalam sebulan untuk 1.000 pengguna aktif?	Menyediakan angka dampak komunitas yang konkret untuk ditampilkan di dashboard Jejak Hijau dan digunakan sebagai impact statement di presentasi capstone
PB-7	Dalam satuan yang lebih relatable: berapa km perjalanan mobil yang setara dengan menyelamatkan 1 kg daging sapi vs 1 kg sayuran?	Memvalidasi logika konversi CO ₂ e ke satuan km berkendara yang digunakan di fitur Jejak Hijau agar angka yang ditampilkan ke pengguna mudah dipahami dan tidak abstrak.

3.2 Pertanyaan dari Ingredients Master dan Dataset Nutrition

No	Pertanyaan	Relevansi untuk SayurKita
PB-5	Kategori bahan apa yang paling banyak digunakan dalam resep, dan seberapa besar kontribusinya terhadap total penggunaan	Memastikan kategori dengan frekuensi tertinggi mendapat prioritas dalam pengembangan dan validasi data Ingredients Master, khususnya untuk akurasi autocomplete di LihatKulkas.
PB-6	Bahan-bahan apa saja yang paling sering digunakan (top 20), dan apakah ketersediaannya sudah mencerminkan prioritas stok yang tepat?	Menentukan urutan seed autocomplete berdasarkan frekuensi penggunaan nyata
PB-7	Bagaimana perbandingan rata-rata umur simpan bahan di kulkas, suhu ruang, dan freezer antar kategori? Kategori mana yang paling rentan pembusukan?	Menjadi basis urutan prioritas notifikasi expiry antarkategori — kategori dengan umur simpan paling pendek di suhu ruang mendapat level urgensi notifikasi tertinggi di sistem.

PB-8	Berapa proporsi bahan yang tergolong berisiko tinggi pembusukan (umur simpan suhu ruang ≤ 3 hari), dan tersebar di kategori apa saja?	Mengkuantifikasi skala masalah pembusukan yang harus diatasi fitur LihatKulkas
PB-9	Bahan apa saja yang paling hemat kalori namun tinggi protein (efisiensi nutrisi tertinggi), dan kategori apa yang mendominasi?	Bahan dengan efisiensi nutrisi tinggi yang hampir expired layak mendapat sorotan tambahan untuk memperkuat motivasi pengguna menyelamatkannya.

4. Exploratory Data Analysis (EDA)

EDA dilakukan pada tiga dataset: resep Indonesia, karbon, dan Ingredients Master + nutrisi. Setiap subbagian mengacu pada pertanyaan bisnis di Bab 3.

4.1 EDA Dataset Resep Indonesia

PB-1: Distribusi Kategori Resep dan Keseimbangannya

Apakah distribusi kategori resep sudah seimbang untuk kebutuhan TF-IDF engine?

Dataset mencakup delapan kategori protein (ayam, sapi, ikan, udang, kambing, tahu, tempe, telur), masing-masing 625 resep. Total: 5.000 resep bersih. CoV antar kategori = 0% — distribusi sempurna setelah enforced selection dari 14.945 resep mentah.

Temuan dan Implikasi: Distribusi seimbang mencegah engine bias ke satu kategori. Rekomendasi tetap beragam untuk semua jenis sisa bahan.

PB-2: Rata-rata Jumlah Bahan per Resep dan Korelasinya dengan Popularitas

Berapa rata-rata bahan per resep, dan apakah jumlah bahan memengaruhi popularitas?

Rata-rata bahan per resep: 12,51 (median 12, min 3, maks 25). Rata-rata langkah: 5,45. Korelasi jumlah bahan vs. popularitas: $r = 0,064$. Korelasi langkah vs. popularitas: $r = 0,027$.

Temuan dan Implikasi: Engine bisa merekomendasikan dari input 2–3 bahan sisa. Korelasi mendekati nol memvalidasi Quality Score multivariabel popularitas saja tidak cukup.

PB-3: Bahan Paling Sering Muncul di Seluruh Resep Indonesia

Bahan apa yang paling sering muncul di seluruh resep, dan bagaimana implikasinya ke autocomplete?

Top 10 bahan terbanyak: bawang putih (707), garam (590), bawang merah (528), air (321), kecap (263), minyak (239), gula (211), jahe (204), daun bawang (186), tomat (183). Tiga teratas adalah bumbu dasar yang ada di hampir semua masakan Nusantara.

Temuan dan Implikasi: Urutan frekuensi ini jadi dasar seed autocomplete LihatKulkas. Akurasi 15 bahan teratas di Ingredients Master harus dijaga ketat karena langsung memengaruhi kualitas rekomendasi.

PB-4: Korelasi Kompleksitas Resep dengan Engagement

Apakah resep yang lebih kompleks cenderung mendapat lebih banyak likes?

Scatter plot Total Steps vs. Loves: $r = 0,027$ tidak ada korelasi. Distribusi loves miring kanan: min 6, median 12, rata-rata 22, maks 939. Resep viral bukan karena kompleksitasnya.

Temuan dan Implikasi: Tidak ada metrik tunggal yang mewakili kualitas resep. Mendukung Quality Score multivariabel. Bobot skor_langkah 20% sudah proporsional.

4.2 EDA Dataset Karbon

PB-5: Kategori Makanan dengan Emisi CO₂e Tertinggi

Kategori makanan mana yang paling besar emisi CO₂e-nya jika terbang?

Dari 536 entri CONCITO: daging sapi tertinggi (≈ 50 kg CO₂e/kg, maks 212,92 kg/kg). Kambing ≈ 25 kg/kg. Sayuran dan tahu/tempe jauh lebih rendah: 0,49–1,52 kg/kg. Selisih sapi vs. sayuran $>30\times$ lipat.

Temuan dan Implikasi: Fitur Jejak Hijau perlu memberi penekanan visual lebih untuk protein hewani. Notifikasi expiry daging sapi punya dampak lingkungan yang jauh lebih besar dibanding sayuran.

PB-6: Proyeksi Dampak Komunitas untuk 1.000 Pengguna Aktif

Berapa total CO₂e yang bisa dicegah SayurKita dalam sebulan untuk 1.000 pengguna aktif?

Asumsi: 1 kg waste/hari/pengguna, 30% berhasil dicegah, 30 hari/bulan. Hasil untuk 1.000 MAU: ~ 9 kg diselamatkan per pengguna/bulan $\rightarrow$ total ~ 45 ton CO₂e/bulan (skenario campuran). Skenario all-sapi: 454 ton CO₂e/bulan.

Temuan dan Implikasi: Angka 45 ton CO₂e/bulan (1.000 MAU) layak dijadikan impact statement di presentasi. Dashboard sebaiknya tampilkan angka total komunitas, bukan per pengguna. *Catatan: ini estimasi simulasi, bukan proyeksi tervalidasi.*

PB-7: Konversi CO₂e ke Satuan Relatable (km Berkendara)

Berapa km berkendara yang setara dengan menyelamatkan 1 kg daging sapi vs. 1 kg sayuran?

Faktor emisi mobil: 0,21 kg CO₂e/km (IPCC & Kemenhut RI). Konversi: 1 kg daging sapi ≈ 240 km, 1 kg kambing ≈ 121 km, 1 kg ayam ≈ 15 km, 1 kg sayuran ≈ 7 km. Rasio sapi vs. sayuran: $\sim 33\times$.

Temuan dan Implikasi: Satuan km lebih relatable. Jejak Hijau pakai ini sebagai default. Notifikasi bisa ditambah: “Daging ayam hampir expired — memasaknya setara hemat 15 km berkendara.”

4.3 EDA Ingredients Master dan Dataset Nutrisi

PB-5: Dominasi Kategori Bahan dalam Penggunaan Resep

Kategori bahan apa yang paling dominan digunakan dalam resep?

Ingredients Master: 1.560 bahan, 8 kategori. Komposisi: bumbu 430 (27,6%), protein_hewani 332 (21,3%), olahan 225 (14,4%), rempah 204 (13,1%), sayuran 130 (8,3%), karbohidrat 113 (7,2%), protein_nabati 80 (5,1%), buah 46 (2,9%). Dari sisi frekuensi kemunculan, bumbu mendominasi karena bawang putih, garam, dan bawang merah ada di hampir semua resep.

Temuan dan Implikasi: Bumbu mendominasi tapi coverage karbon-nya baru 36% — perlu dilengkapi di iterasi berikutnya.

PB-6: Top 20 Bahan Paling Sering Digunakan

Bahan apa saja yang masuk top 20 frekuensi penggunaan?

Top 20: bawang putih (707), garam (590), bawang merah (528), air (321), kecap (263), minyak (239), gula (211), jahe (204), daun bawang (186), tomat (183), cabai merah (177), kemiri (174), ketumbar (163), kunyit (160), lengkuas (155), santan (149), daun salam (143), minyak goreng (138), cabai rawit (130), lada/merica (125). Semua bumbu atau rempah.

Temuan dan Implikasi: Urutan ini jadi seed autocomplete LihatKulkas. Tiga teratas (bawang putih, garam, bawang merah) harus akurat di Ingredients Master — error di sini berdampak ke mayoritas resep.

PB-7: Perbandingan Umur Simpan per Kategori Bahan

Kategori mana yang paling rentan busuk berdasarkan data umur simpan?

Protein hewani: suhu ruang $\approx$ 0,4 hari, kulkas $\approx$ 3,9 hari, freezer $\approx$ 97,5 hari — paling rentan. Sayuran: suhu ruang $\approx$ 2,7 hari, kulkas $\approx$ 7,8 hari. Bumbu dan rempah tahan lama: 254 dan 170 hari di suhu ruang. Karbohidrat: $\approx$ 230 hari.

Temuan dan Implikasi: Urutan prioritas notifikasi: protein_hewani > sayuran > olahan > buah > protein_nabati > karbohidrat > rempah > bumbu. Daging mendekati hari ke-3 di kulkas → urgensi tertinggi. Sistem juga bisa sarankan pindah ke freezer jika tidak dimasak dalam 1 hari.

PB-8: Proporsi Bahan Berisiko Tinggi Pembusukan

Berapa proporsi bahan berisiko tinggi busuk, dan di kategori mana saja?

Klasifikasi: Tinggi (≤ 3 hari), Sedang (4–7 hari), Rendah (> 7 hari). Dari 1.560 bahan: 917 (58,8%) Tinggi, 134 (8,6%) Sedang, 509 (32,6%) Rendah. Terbanyak berisiko tinggi: protein_hewani (312), olahan (189), bumbu (154), sayuran (115).

Temuan dan Implikasi: 58,8% bahan dapur mudah rusak dalam 3 hari — memperkuat urgensi notifikasi expiry sebagai fitur inti MVP. Kolom risiko_suhu_ruang yang sudah tersedia di Ingredients Master dapat langsung digunakan sebagai sinyal prioritas notifikasi, dengan pengurutan: bahan Tinggi mendapat notifikasi lebih agresif dibanding Sedang atau Rendah.

PB-9: Efisiensi Nutrisi Bahan Dapur (Protein per Kalori)

Bahan apa yang paling tinggi efisiensi nutrisinya (protein per kalori)?

Dihitung dari 448 bahan dengan data kalori dan protein valid. Efisiensi tertinggi: ikan (kakap, kembung, tongkol), daging sapi, dan ayam. Bumbu/rempah tidak signifikan secara makronutrien karena dipakai dalam jumlah kecil.

Temuan dan Implikasi: Ikan → prioritas ganda: efisiensi nutrisi tinggi + umur simpan pendek. Nutrition Rescue Card di fitur Selamatkan bisa highlight nilai protein bahan yang hampir expired. Coverage analisis ini 28,7% dari total bahan (keterbatasan data gizi).

5. Key Findings

Bagian ini menyintesis temuan lintas dataset menjadi tiga narasi yang menjawab pertanyaan bisnis inti secara terpadu.

5.1 Kesiapan Data untuk TF-IDF Engine

Dataset resep yang dihasilkan memenuhi prasyarat teknis TF-IDF dari sisi volume (5.000 resep), keseimbangan distribusi (625 per kategori, CoV = 0% setelah enforced selection), dan kualitas teks (sudah dinormalisasi lowercase). Dengan rata-rata 12,51 bahan per resep dan rentang 3 sampai 25 bahan, engine berpotensi menghasilkan rekomendasi bahkan dari input 2 sampai 3 bahan sisa.

Temuan dari PB-2 dan PB-4 (korelasi $r = 0,064$ dan $r = 0,027$) menunjukkan bahwa kualitas resep bersifat multidimensi dan tidak dapat diwakili oleh satu variabel tunggal. Ini mendukung penggunaan Quality Score yang menggabungkan beberapa faktor daripada seleksi berdasarkan satu metrik saja.

5.2 Protein Hewani sebagai Kategori Prioritas dalam Tiga Dimensi

Analisis lintas tiga dimensi menunjukkan bahwa protein hewani secara konsisten muncul sebagai kategori yang paling perlu mendapat perhatian dalam sistem SayurKita:

1. Dimensi waktu: median umur kulkas hanya 3 hari dan 94% bahan berisiko tinggi di suhu ruang. Ini adalah tingkat risiko tertinggi di antara semua kategori.
2. Dimensi frekuensi: kategori ayam, telur, ikan, dan sapi masing-masing memiliki 625 resep dalam dataset. Ini menunjukkan bahwa bahan protein hewani banyak digunakan dalam masakan Nusantara.
3. Dimensi lingkungan: rata-rata emisi CO₂e tertinggi (20,55 kg/kg) dengan cakupan data karbon yang sudah baik (92% dari 332 bahan).

5.3 Gap Coverage Data dan Strategi Penanganan

Terdapat dua gap coverage yang perlu ditangani dengan strategi fallback yang terdefinisi:

Jenis Gap	Coverage Aktual	Kategori Terdampak	Strategi Penanganan
Data gizi (kalori, protein, dsb.)	28,7% - 448 dari 1.560 bahan	Semua kategori	Tampilkan Nutrition Card hanya jika kalori_per_100g lebih dari 0. Jangan tampilkan card dengan nilai kosong.
Data karbon CO ₂ e	58,3% - 910 dari 1.560 bahan	Bumbu 36%, Rempah 33%	Gunakan median kategori sebagai nilai fallback, bukan nilai nol.

Coverage data karbon pada kategori bumbu (36%) dan rempah (33%) masih terbatas dan menjadi salah satu area yang perlu dilengkapi pada iterasi berikutnya. Coverage data gizi secara keseluruhan juga masih rendah (28,7%) karena keterbatasan nama bahan yang cocok antara dataset nutrisi Kaggle dengan Ingredients Master.

6. Carbon Intelligence Pipeline

Ini adalah salah satu kontribusi teknis paling unik dalam pipeline DS SayurKita — sistem pencocokan nama bahan Indonesia dengan nilai CO₂e menggunakan pendekatan multi-layer matching.

6.1 Tantangan Pencocokan

Dataset carbon (536 entri, format bahasa Indonesia dari CONCITO) memiliki struktur nama yang berbeda jauh dari nama bahan di Ingredients Master (1.560 bahan). Contoh:

Ingredients Master: 'daging ayam', 'dada ayam', 'ayam kampung', 'fillet ayam'

- Carbon Dataset: 'daging dada ayam dan kulit mentah', 'ayam rata-rata', 'ayam cincang'

Simple exact matching tidak akan berhasil. Diperlukan strategi matching berlapis.

6.2 Arsitektur 3-Layer Matching

Pra-Layer: Manual Map (Presisi Tertinggi)

Untuk bahan-bahan protein hewani yang paling berdampak dan paling sering muncul, dibuat MANUAL_MAP, dictionary pemetaan eksplisit nama bahan ke entri carbon yang paling tepat

Layer 1: Exact Match

Setelah normalisasi (lowercase + strip), cek apakah nama bahan ada persis di carbon dictionary. Menangani kasus di mana nama sudah sinkron setelah normalisasi efisien untuk bumbu dan rempah yang namanya pendek dan konsisten.

Layer 2: Token Match

Aturan berbasis keyword containment yang divalidasi secara manual (TOKEN_RULES). Contoh: jika nama bahan mengandung kata 'bawang putih', peta ke 'bawang putih mentah'. Lebih aman dari fuzzy karena tidak menghasilkan false positive dari kesamaan string yang tidak bermakna.

Layer 3: Fuzzy Match

Menggunakan library rapidfuzz dengan algoritma token_sort_ratio dan threshold skor 85%. Token sort ratio dipilih karena menormalisasi urutan kata sebelum membandingkan — cocok untuk nama bahan yang kata-katanya sama tapi urutan berbeda.

6.3 Hasil Carbon Merge

Pipeline dijalankan pada seluruh 1.560 bahan di Ingredients Master dengan hasil sebagai berikut:

Layer Matching	Jumlah Bahan	Persentase
Pra-Layer: Manual Map	±400	~25.6%
Layer 1: Exact Match	±150	~9.6%
Layer 2: Token Match	±100	~6.4%
Layer 3: Fuzzy Match	±260	~16.7%
No Match (NaN)	650	41.7%
TOTAL MATCHED	910	58.3%

7. Dashboard Development and Deployment

6.1 Gambaran Umum

Dashboard analitik SayurKita dibangun menggunakan Python dan Streamlit, di-deploy di sayurkita-dashboard.streamlit.app. Dashboard ini berfungsi sebagai dokumentasi interaktif dari proses analisis data, bukan aplikasi SayurKita itu sendiri. Tujuannya adalah memberikan akses visual terhadap temuan analisis sebelum data diintegrasikan ke aplikasi utama.

Statistik ringkasan yang ditampilkan di halaman Gambaran Umum:

Metrik	Nilai	Sumber
Kumpulan Data Resep Mentah	14.945 baris	Dataset CSV Kaggle (Canggih)
Resep Terkurasi	5.000 resep, 625 per kategori	Hasil pipeline cleaning DS
Bahan Unik di Master	1.560 bahan	Ingredients Master buatan DS
Kategori Emisi CO2e	536 faktor emisi	The Big Climate Database (CONCITO)
Estimasi Limbah Pangan Nasional	48 juta ton per tahun	Bappenas 2021, GRASP 2030
Estimasi Kerugian Finansial	Rp 551 triliun per tahun	Bappenas 2021

Tim DS menghasilkan serangkaian visualisasi analitik yang tersebar di tiga notebook (EDA Resep+Karbon, Ingredients Master, dan Nutrition). Visualisasi ini berfungsi ganda: dokumentasi proses dan materi presentasi capstone.

Visualisasi	Jenis Chart	Pertanyaan yang Dijawab	Digunakan di
Distribusi kategori resep (bar + pie)	Horizontal bar + Donut chart	Seberapa seimbang distribusi data resep?	Slide presentasi capstone
Scatter plot bahan vs loves (+ trendline)	Scatter + linear regression line	Apakah bahan sedikit = lebih populer?	Justifikasi quality score formula
Top-15 bahan paling sering digunakan	Horizontal bar dengan color-coding kategori	Bahan apa yang harus jadi prioritas di Ingredients Master?	Dokumentasi + rekomendasi aksi
Perbandingan umur simpan per kategori	Grouped bar chart (3 kondisi)	Kategori mana yang paling rentan pembusukan?	Slide presentasi + UX brief untuk FS Dev
Distribusi risiko pembusukan (donut)	Donut chart + breakdown per kategori	Berapa persen bahan berisiko tinggi?	Slide presentasi capstone
Efisiensi nutrisi top-15 bahan	Horizontal bar + scatter (protein vs kalori)	Bahan mana yang sayang dibuang secara gizi?	Nutrition Rescue Card brief untuk FS Dev
CO ₂ e per kategori (bar chart)	Horizontal bar dengan color coding merah-hijau	Kategori mana yang paling berdampak lingkungan?	Slide presentasi — most impactful visual

Simulasi dampak 1.000 user	Bar chart proyeksi per kategori	Seberapa besar dampak SayurKita secara kuantitatif?	Slide presentasi — closing impact statement
Konversi CO₂e ke km berkendara	Bar chart + annotated comparison chart	Berapa 'km tidak berkendara' dari 1 kg makanan diselamatkan?	Brief untuk UI Jejak Hijau di FS Dev

6.2 Struktur Section Dashboard

Dashboard terdiri dari enam section yang dapat diakses melalui navigasi sidebar:

1. Gambaran Umum: statistik kunci, peta transformasi data (alur dari dataset raw ke output), dan tech stack proyek.
2. Analisis Dataset Resep: distribusi kategori raw dan bersih, top 10 bahan paling sering muncul, dan scatter plot korelasi kompleksitas versus popularitas.
3. Bahan dan Nutrisi: donut chart distribusi kategori Ingredients Master, histogram distribusi umur simpan di kulkas, justifikasi fitur notifikasi expiry, dan Top 5 bahan dengan kandungan protein tertinggi dari dataset nutrisi.
4. Dampak Jejak Karbon: bar chart top 15 faktor emisi CO₂e tertinggi dari dataset karbon, dan kalkulator simulasi dampak komunitas dengan dua slider input.
5. Kumpulan Data Wawasan Lintas: formula skor prioritas multidimensi dan daftar lima bahan dengan skor prioritas tertinggi berdasarkan algoritma tersebut.
6. Analisis Berdasarkan Notebook: reproduksi analisis dari dua notebook dengan format Pertanyaan Bisnis, Visualisasi, kemudian Temuan dan Implikasi. Tersedia dalam dua tab: Notebook A untuk Dataset Resep dan Karbon, serta Notebook B untuk Ingredients Master dan Nutrisi.

6.3 Kalkulator Simulasi Dampak Komunitas

Section Dampak Jejak Karbon menyediakan kalkulator simulasi interaktif. Parameter yang dapat disesuaikan pengguna:

1. Jumlah Pengguna Aktif Bulanan (MAU): dapat diatur dalam rentang tertentu menggunakan slider.
2. Rata-rata bahan yang diselamatkan per pengguna per hari dalam satuan gram.

Pada setting default (1.000 MAU, 500 gram per hari), output kalkulator menunjukkan: sekitar 15.000 kg massa organik tidak terbuang per bulan, sekitar 45.000 kg CO₂e berkurang, dan setara dengan sekitar 214 ribu km perjalanan mobil.

Catatan metodologi: Angka dari kalkulator adalah estimasi simulasi berdasarkan asumsi rata-rata, bukan proyeksi yang divalidasi. Faktor emisi mengacu pada The Big Climate Database

(CONCITO) yang berbasis data produksi di negara-negara Eropa. Nilai aktual untuk Indonesia dapat berbeda.

7. Conclusion

7.1 Dataset Resep

Dari 14.945 resep mentah, proses cleaning dan seleksi menghasilkan 5.000 resep bersih dengan distribusi 625 resep per delapan kategori. Normalisasi teks dan seleksi berbasis Quality Score menghasilkan dataset yang siap digunakan sebagai input TF-IDF engine tanpa preprocessing tambahan. Analisis korelasi menunjukkan bahwa tidak ada variabel sederhana yang memadai sebagai proxy kualitas resep ($r = 0,064$ untuk bahan dan $r = 0,027$ untuk langkah vs popularitas), yang mendukung penggunaan Quality Score multivariabel.

7.2 Ingredients Master

Ingredients Master dengan 1.560 entri merupakan dataset yang dibangun dari nol oleh tim DS karena tidak tersedia padanannya secara publik untuk konteks bahan dapur Indonesia. Data umur simpan terisi lengkap 100% untuk seluruh entri, yang merupakan prasyarat utama sistem notifikasi expiry. Coverage data gizi sebesar 28,7% berarti Nutrition Rescue Card hanya dapat aktif untuk sebagian kecil bahan. Coverage karbon mencapai 58,3% secara keseluruhan, dengan cakupan lebih baik pada kategori protein hewani (92%) dan sayuran (93%).

7.3 Carbon Analysis

Analisis menggunakan data dari The Big Climate Database (CONCITO) menunjukkan perbedaan yang signifikan antarkategori pangan. Rata-rata emisi protein hewani (20,55 kg/kg) jauh di atas kategori lain, dengan nilai median 5,70 kg/kg. Sayuran memiliki rata-rata terendah (0,49 kg/kg). Konversi ke satuan km berkendara dilakukan agar angka yang ditampilkan lebih mudah dipahami oleh pengguna yang tidak terbiasa dengan satuan emisi.

7.4 Keterbatasan dan Tantangan

1. Coverage data gizi hanya 28,7% dari total bahan karena keterbatasan kecocokan nama antara dataset nutrisi Kaggle dengan Ingredients Master. Nutrition Rescue Card tidak akan aktif untuk sebagian besar entri.
2. Quality Score tidak divalidasi dengan metrik evaluasi sistem rekomendasi seperti precision@k atau recall@k karena tidak tersedia data ground truth preferensi pengguna.
3. Data umur simpan diisi berdasarkan TKPI Kemenkes dan StillTasty.com. Kondisi penyimpanan aktual di rumah tangga Indonesia yang bervariasi dapat menghasilkan nilai yang berbeda.

4. The Big Climate Database (CONCITO) menggunakan bahasa Indonesia, namun nama-nama bahan sering merupakan terjemahan langsung dari bahasa Denmark/Inggris yang tidak lazim digunakan di Indonesia sehari-hari. Contoh: 'bandeng hering mentah' untuk ikan bandeng, 'nilai rata-rata daging domba mentah' untuk kambing. Ini mengharuskan pembuatan MANUAL_MAP yang ekstensif dan time-consuming.
5. Dataset resep Cookpad Indonesia mengandung variasi penulisan bahan yang sangat tinggi: 'dada ayam', 'dada ayam fillet', 'fillet dada ayam', 'ayam dada', 'dada fillet', 'fillet ayam', 'filet ayam' — semua merujuk pada bahan yang sama. Proses normalisasi regex hanya mengatasi sebagian masalah ini; kasus edge masih ada di Ingredients Master.
6. 41.7% bahan (650 dari 1.560) tidak mendapat nilai CO₂e karena tidak ada padanan yang cukup dekat di database CONCITO. Mayoritas adalah bumbu dan rempah spesifik Indonesia (kemiri, terasi, serai, daun jeruk, dll.) yang memang tidak ada dalam database berbasis Eropa tersebut.
7. Faktor emisi CO₂e dari The Big Climate Database berbasis data produksi Eropa. Nilai aktual untuk Indonesia berpotensi berbeda karena perbedaan praktik pertanian dan rantai pasok lokal.

8. Recommendations

1. Perluas Ingredients Master ke lebih dari 500 bahan dengan mengintegrasikan data TKPI Kemenkes secara lebih sistematis, termasuk penambahan data umur simpan untuk bahan yang belum tercakup.
2. Tingkatkan coverage data gizi melalui penambahan sumber referensi, misalnya FoodData Central USDA dengan penyesuaian nama bahan ke konteks Indonesia.
3. Tambahkan mekanisme feedback di aplikasi untuk mengumpulkan data preferensi pengguna secara implisit. Data ini akan memungkinkan evaluasi dan penyempurnaan Quality Score secara lebih berbasis data.
4. Untuk data karbon, pertimbangkan mencari faktor emisi yang lebih spesifik untuk konteks produksi pangan Indonesia, mengingat The Big Climate Database berbasis data Eropa.

9. References

- Bappenas. (2021). Laporan Kajian Sektor Pangan Nasional: Estimasi Nilai Kerugian Food Waste Indonesia. Badan Perencanaan Pembangunan Nasional Republik Indonesia.
- GRASP 2030. (2025). Food Loss and Waste in Indonesia: Updated National Assessment. GRASP Global Report.
- CONCITO. (2024). The Big Climate Database v2.0 - LCA Food Database. Lisensi CC-BY 4.0. <https://www.thebigclimatedatabase.com>
- Kementerian Kesehatan RI. (2017). Tabel Komposisi Pangan Indonesia (TKPI). Direktorat Jenderal Kesehatan Masyarakat, Kemenkes RI.
- Kementerian Lingkungan Hidup dan Kehutanan RI. (2023). Faktor Emisi Listrik PLN Indonesia 2023. KLHK RI.

IPCC. (2014). Climate Change 2014: Mitigation of Climate Change - Transport Sector Emission Factors. Intergovernmental Panel on Climate Change.

Media Gizi Indonesia. (2025). Riset Pola Pemborosan Makanan Rumah Tangga Indonesia. Media Gizi Indonesia.

Canggih. (2021). Indonesian Food Recipes Dataset. Kaggle. <https://www.kaggle.com/datasets/canggih/indonesian-food-recipes>

Anasfikri, H. (2021). Indonesian Food and Drink Nutrition Dataset. Kaggle. <https://www.kaggle.com/datasets/anasfikrihanif/indonesian-food-and-drink-nutrition-dataset>

StillTasty.com. (2024). Food Storage Database - Shelf Life Reference. <https://www.stilltasty.com>

Appendix

A. Data Dictionary - clean_recipes_5000_with_score.csv

Kolom	Tipe Data	Deskripsi
Title	string	Judul asli resep dalam bahasa Indonesia
Ingredients	string	Daftar bahan lengkap dalam format teks mentah dari Cookpad
Steps	string	Langkah-langkah memasak dalam format teks
Loves	integer	Jumlah engagement (loves) dari pengguna Cookpad. Min: 6, Median: 12, Max: 939
URL	string	URL sumber resep di platform Cookpad
Category	string	Kategori protein utama: ayam, sapi, ikan, udang, kambing, tahu, tempe, telur
Title Cleaned	string	Judul resep setelah normalisasi teks
Total Ingredients	integer	Jumlah bahan dalam resep. Range: 3 sampai 25, rata-rata 12,51
Ingredients Cleaned	string	Daftar bahan setelah normalisasi lowercase dan strip karakter
Total Steps	integer	Jumlah langkah memasak. Range: 2 sampai 23, rata-rata 5,45
judul_bersih	string	Judul bersih hasil preprocessing akhir
bahan_bersih	string	Bahan bersih hasil preprocessing akhir
Quality Score	float	Skor kualitas komposit rentang 0 sampai 1. Min: 0,08, Rata-rata: 0,30, Max: 0,80

B. Data Dictionary - Indonesian Food Nutrition (raw dan cleaned)

Dataset raw (nutrition.csv) memiliki 1.346 baris dan 7 kolom. Dataset cleaned (nutrition_cleaned.csv) memiliki 1.244 baris dan 5 kolom setelah penghapusan 102 duplikat dan penyesuaian nama kolom.

Kolom Raw	Kolom Cleaned	Tipe Data	Deskripsi
id	(dihapus)	-	Nomor identifikasi, tidak digunakan dalam analisis
name	nama_bersih	string	Nama bahan dalam format lowercase. Digunakan sebagai join key. 1.244 nilai unik setelah cleaning.
calories	kalori_per_100g	float	Kandungan energi per 100g dalam kkal. Range: 0 sampai 902. Rata-rata: 200,78.
proteins	protein_g	float	Kandungan protein per 100g dalam gram. Range: 0 sampai 83.
fat	lemak_g	float	Kandungan lemak per 100g dalam gram.
carbohydrate	karbo_g	float	Kandungan karbohidrat per 100g dalam gram.
image	(dihapus)	-	URL foto bahan, tidak digunakan dalam analisis

C. Data Dictionary - ingredients_master_final

Kolom	Tipe Data	Deskripsi
nama_id	string	Nama bahan standar Indonesia (lowercase). Key utama di seluruh sistem.
frekuensi	integer	Jumlah kemunculan bahan dalam 5.000 resep bersih. Tertinggi: bawang putih (707).
kategori	string	Delapan kategori: bumbu, protein_hewani, olahan, rempah, sayuran, karbohidrat, protein_nabati, buah.
umur_kulkas	integer	Estimasi umur simpan (hari) pada suhu kulkas sekitar 4 derajat Celcius. Coverage: 100%. Sumber: TKPI Kemenkes dan StillTasty.com.
umur_suhu_ruang	integer	Estimasi umur simpan (hari) pada suhu ruang 25 sampai 30 derajat Celcius. Coverage: 100%.

umur_freezer	integer	Estimasi umur simpan (hari) pada suhu freezer kurang dari atau sama dengan -18 derajat Celcius. Nilai 0 berarti tidak disarankan dibekukan. Coverage: 100%.
kalori_per_100g	float	Kandungan kalori per 100g dalam kkal. Nilai 0 berarti data tidak tersedia. Coverage bermakna: 28,7% (448 bahan).
protein_g	float	Kandungan protein per 100g dalam gram. Nilai 0 berarti data tidak tersedia.
lemak_g	float	Kandungan lemak per 100g dalam gram. Nilai 0 berarti data tidak tersedia.
karbo_g	float	Kandungan karbohidrat per 100g dalam gram. Nilai 0 berarti data tidak tersedia.
karbon_co2e	float	Emisi CO2 equivalen per kg bahan (kg CO2e). NULL berarti belum tersedia. Coverage: 58,3% (910 bahan). Sumber: The Big Climate Database (CONCITO).

D. Ringkasan Coverage Data per Kategori Ingredients Master

Kategori	Total	Umur Simpan	Kalori > 0	CO2e Tersedia	CO2e NULL
bumbu	430	100%	22%	36%	64%
protein_hewani	332	100%	34%	92%	8%
olahan	225	100%	16%	42%	58%
rempah	204	100%	40%	33%	67%
sayuran	130	100%	28%	93%	7%
karbohidrat	113	100%	29%	51%	49%
protein_nabati	80	100%	52%	91%	9%
buah	46	100%	22%	74%	26%